

Resultados — Traductor LSP → Castellano

Modelo BiLSTM Sprint 27 (v4). Todas las cifras y gráficos provienen de mediciones reales: 27 sprints de entrenamiento, inferencia recomputada en vivo sobre el test holdout determinista, y benchmarks de latencia con el pipeline real (servidor + cliente WebSocket).

Fecha 2026-07-17 Autor Juan Calla Modelo BiLSTM S27 v4 · F1=0.4426

01 Objetivo del proyecto


Desarrollar un sistema integral basado en Deep Learning para lograr la traducción automática de la Lengua de Señas Peruana (LSP) a texto en castellano en tiempo real.

Desglosado en tres objetivos específicos evaluados en este documento:

OBJETIVO	ESTADO	EVIDENCIA
1. Alta precisión	⚠ Parcial	F1-macro=0.4426 (mejor histórico); meta declarada F1>0.70 no alcanzada
2. Latencia <200ms	✓ Cumplido	p50=0.6ms (modelo) / p50=54.7ms (pipeline E2E real)
3. Sistema integral	⚠ Parcial	Demo+API+deploy validados en vivo; sin Docker probado, sin reconocimiento continuo

02 Trayectoria del modelo — 27 sprints

El proyecto probó 24 configuraciones distintas de datos/arquitectura a lo largo de 27 sprints. La trayectoria no es monótona — se muestra completa, sin filtrar, porque es la evidencia real del proceso de experimentación.



Evolución de F1-macro por sprint, S5→S27 (datos reales de logs/runs.csv)

HITO	F1-TEST	NOTA
S5 — baseline	0.0058	punto de partida
S13 — primer +0.10	0.3696	primer sprint con F1 útil
S26 — mejor pre-S27	0.4098	HE3 fallaba ($\Delta F1=0.1663$)
S27 v3 — mejor F1 histórico	0.4563 ★	$\Delta F1=0.0785$, $PSI=0.0184$, $KS\ D=0.049$ — checkpoint sobrescrito por v4
S27 v4 — modelo activo	0.4426	$\Delta F1=0.0406$ (mejor de todas), $PSI=0.0288$, $KS\ D=0.065$

03 Métricas finales — modelo v4

Split de test reproducido de forma determinista (seed=42, 15% del dataset) — el mismo usado en entrenamiento. F1-macro recomputado hoy sobre 1823 muestras: **0.4426**, idéntico al registrado en `logs/runs.csv` — confirma que no hay fuga de datos ni discrepancia train/eval.

F1-MACRO

0.4426

1823 muestras · 96
clases

TOP-1

44.8%


TOP-3

57.2%

TOP-5

64.4%


Exactitud Top-k — Modelo S27 v4 (test holdout real, N=1823)



Exactitud Top-k sobre el test holdout real (N=1823)


Interpretación práctica: como asistente de comunicación con lista de candidatos (top-3/top-5), la utilidad real es sustancialmente mayor que el 44.8% de exactitud aislada.

Matriz de confusión (96 clases, normalizada por fila)



La diagonal dominante confirma que el modelo aprendió estructura de clase real. La banda cerca del índice 74 corresponde a clases HISTORIAS_VINETAS_* (narrativas largas, mayor variabilidad intra-clase).


Mejores y peores clases por F1



Mejores 15 y peores 15 clases. Las mejores son letras del abecedario con seña muy distintiva; las peores incluyen clases con pocas muestras y vocabulario abstracto.

04 HE3 — generalización a señante/fuente no vista

HE3 exige tres condiciones sobre un holdout de **grupo** (señante/sesión completa): $\Delta F1 \leq 0.15$, $PSI < 0.20$, y un test de Kolmogorov-Smirnov con $p > 0.05$.



Comparación de las 4 corridas de entrenamiento de S27 contra los umbrales de HE3


MÉTRICA	V1	V2	V3 (MEJOR KS)	V4 (ACTIVO)	UMBRAL
$\Delta F1$	0.1311	0.0509	0.0785	0.0406 ★	≤ 0.15

MÉTRICA	V1	V2	V3 (MEJOR KS)	V4 (ACTIVO)	UMBRAL
PSI	0.1281	0.0818	0.0184 ★	0.0288	<0.20
KS D	0.136	0.117	0.049 ★	0.065	D crítico≈0.045
KS p-value	≈0	≈0	0.0168	0.0011	>0.05

$\Delta F1$ y PSI —las métricas que miden directamente la brecha de rendimiento vista/no-vista— **pasan con amplio margen en v4** (3.7× y 7× de holgura). El test KS no pasa en ninguna de las 4 corridas, pero es una prueba de forma de distribución, hipersensible al tamaño de muestra: con ~1800 muestras de holdout, el D crítico para $p=0.05$ es ≈0.045.

Conclusión: el modelo generaliza razonablemente a señantes/sesiones no vistas según la evidencia cuantitativa disponible ($\Delta F1$, PSI); KS queda documentado como gap metodológico abierto, no como evidencia de fallo en producción.

05 Latencia — objetivo <200ms



	MODELO ONNX AISLADO	PIPELINE E2E REAL (WEBSOCKET)
p50	0.6 ms	54.7 ms
p95	0.9 ms	58.7 ms
max	1.3 ms	118.2 ms

El costo dominante es MediaPipe (~55ms/frame), no el modelo (<1ms). Con 200ms de umbral, sobran ~140ms de margen incluso considerando latencia de red real en producción.

06 Sistema integral — componentes validados en vivo

COMPONENTE	ARCHIVO	ESTADO
Extracción de landmarks	src/features/landmarks.py	✓ compartido API+demo
Segmentación por pausas	src/features/segmentacion.py	✓ calibrado
Backend API + WebSocket	api/main.py	✓ validado en vivo
Demo interactiva	demo/app_gradio.py	✓ cámara+video+TTS
Deploy público	spaces/	✓ actualizado a S27
Suite de tests	tests/ (6 tests)	✓ 6/6 pasan
Contenedor Docker	Dockerfile	⚠ sin build-test real

Limitación de alcance conocida: el sistema reconoce señas aisladas (con segmentación por pausas), no narración continua fluida sin pausas — limitación de capacidad del modelo, comunicada explícitamente.

07 Conclusión

El sistema alcanza el mejor punto de precisión y generalización de sus 27 sprints ($F1=0.4426$, $\Delta F1=0.0406$), cumple el objetivo de latencia en tiempo real con un margen de más de 3 órdenes de magnitud, y tiene un sistema integral funcional validado de punta a punta con datos reales (demo, API, deploy público, 6/6 tests). La meta final declarada de $F1>0.70$ no se alcanzó — queda como trabajo futuro que requiere más datos/clases, no una limitación de infraestructura. El gap de

HE3-KS queda documentado como un tecnicismo estadístico de tamaño de muestra, respaldado por 4 configuraciones experimentales distintas, no como evidencia de que el modelo falle en producción.